

CPE 342 Machine Learning

Assignment 3: Regression — Survival Analysis

Estimating Customer Lifetime on Telco Churn Dataset

67070501042 วิศิษฐ์ สุวรรณเนา

1. ภาพรวมของปัญหาและวัตถุประสงค์ (Problem Overview & Objectives)

ในงานมอบหมายส่วนของ Activity นี้ เราศึกษาและวิเคราะห์พฤติกรรมการคงอยู่และการยกเลิกบริการของลูกค้า (Customer Retention & Churn Dynamics) โดยประยุกต์ใช้ระเบียบวิธี การวิเคราะห์การอยู่รอด (Survival Analysis) ด้วยตัวประมาณค่าแบบนอนพารามิเตอร์ **Kaplan-Meier Estimator** บนชุดข้อมูล **Telco-Churn.csv** ซึ่งประกอบด้วยข้อมูลลูกค้ารวม $N = 7,043$ ราย

วัตถุประสงค์หลักของการวิเคราะห์

1. เพื่อสร้างตัวแปรระยะเวลาการใช้บริการ $T = \text{tenure}$ (หน่วย: เดือน) และตัวบ่งชี้การเกิดเหตุการณ์ยกเลิกบริการ $E = \mathbb{I}(\text{Churn} == \text{'Yes'})$
2. เพื่อจัดการปัญหา ข้อมูลถูกจำกัดช่วงทางขวา (Right-Censoring) สำหรับลูกค้าที่ยังคงใช้บริการอยู่ ณ ปัจจุบัน ($E = 0$)
3. เพื่อประมาณค่าฟังก์ชันการอยู่รอดของประชากรโดยรวม $\hat{S}(t)$ พร้อมคำนวณช่วงความเชื่อมั่น 95% ด้วยสูตรของ Greenwood
4. เพื่อเปรียบเทียบวิธีการอยู่รอดและความเสี่ยงในการยกเลิกบริการระหว่างช่องทางการชำระเงินทั้ง 4 รูปแบบ (**PaymentMethod**): **Electronic check**, **Mailed check**, **Bank transfer (automatic)** และ **Credit card (automatic)**
5. เพื่อทดสอบนัยสำคัญทางสถิติด้วยการทดสอบ **Log-Rank Test** (ทั้งแบบ Multivariate และ Pairwise) เพื่อยืนยันความแตกต่างของเส้นโค้งการอยู่รอดอย่างมีนัยสำคัญ ($p < 0.001$)
6. เพื่อนำผลลัพธ์เชิงปริมาณและค่าความน่าจะเป็น ณ ช่วงเวลาสำคัญ ($t = 12, 24, 36, 48, 60, 72$ เดือน) ไป แปล ผล เชิง ธุรกิจ และ เสนอ แนวทาง ลด อัตรา การ ยกเลิก บริการ (Churn Mitigation Strategy)

2. กรอบทฤษฎีและคณิตศาสตร์

(Theoretical Framework & Mathematical Formulations)

2.1 ข้อจำกัดของ Regression ทั่วไปกับข้อมูล Time-to-Event

(Limitations of Standard Regression on Censored Data)

ในการวิเคราะห์ข้อมูลระยะเวลาจนกระทั่งเกิดเหตุการณ์ (Time-to-Event Data) เช่น การยกเลิกบริการของลูกค้า การใช้สมการถดถอยเชิงเส้น (Linear Regression) หรือ Logistic Regression ทั่วไปมีข้อจำกัดร้ายแรงดังนี้ (อิงตาม Lecture 4 หน้า 27–33):

- **การติดปัญหา Right-Censoring:** ลูกค้าส่วนใหญ่ (73.46%) ยังไม่ยกเลิกบริการในวันที่เก็บข้อมูล เราจึงรู้ว่าระยะเวลาของลูกค้าเหล่านี้มีค่าอย่างน้อยเท่ากับ t ($T \geq t$) แต่ไม่รู้เวลาสิ้นสุดจริง หากตัดข้อมูลเหล่านี้ทิ้งจะเกิดภาวะความลำเอียงจากการคัดออก (Selection Bias) หรือหากนับว่า t คือเวลาสิ้นสุด โมเดลจะประเมินอายุขัยของลูกค้าต่ำกว่าความเป็นจริง (Underestimation)
- **การแจกแจงแบบเบ้และค่าเป็นบวกเสมอ:** ตัวแปรเวลา $T \geq 0$ มีลักษณะการแจกแจงแบบเบ้ขวา (Positive Skewness) ซึ่งละเมิดข้อสมมติฐาน Normal Distribution ของ Ordinary Least Squares (OLS)
- **Logistic Regression ขาดมิติของเวลา:** Logistic Regression สนใจเพียงแค่เกิดเหตุการณ์หรือไม่ ณ จุดสิ้นสุดการทดลอง แต่ไม่สามารถตอบได้ว่าลูกค้ายกเลิกบริการที่เวลาใด หรือความน่าจะเป็นที่จะอยู่รอดผ่านปีที่ 1 หรือปีที่ 2 เป็นเท่าใด

2.2 นิยามทางคณิตศาสตร์ของฟังก์ชันการอยู่รอดและความเสี่ยง

(Mathematical Definitions of Survival & Hazard Functions)

กำหนดให้ $T \geq 0$ เป็นตัวแปรสุ่มชนิดต่อเนื่องแทนระยะเวลาจนกว่าจะเกิดเหตุการณ์ โดยมีฟังก์ชันความหนาแน่นความน่าจะเป็น $f(t)$ และฟังก์ชันการแจกแจงสะสม $F(t) = P(T < t)$

1. ฟังก์ชันการอยู่รอด (Survival Function: $S(t)$)

ฟังก์ชัน $S(t)$ คือความน่าจะเป็นที่ลูกค้ารายหนึ่งจะยังคงใช้บริการอยู่เกินกว่าเวลา t

$$S(t) = P(T \geq t) = 1 - F(t) = \int_t^\infty f(u) du \quad (1)$$

โดยมีคุณสมบัติทางคณิตศาสตร์คือ: $S(0) = 1$ (ณ จุดเริ่มต้น ลูกค้าทุกคนยังอยู่), $S(\infty) = 0$ (เมื่อเวลาผ่านไปไม่สิ้นสุด ทุกคนจะเกิดเหตุการณ์) และ $S(t)$ เป็นฟังก์ชันลดลงทางเดียวหรือไม่เพิ่มขึ้น (Monotonically Non-increasing)

2. ฟังก์ชันความเสี่ยง (Hazard Function: $\lambda(t)$ หรือ $h(t)$)

ฟังก์ชัน $\lambda(t)$ แทนอัตราความเสี่ยงขณะใดขณะหนึ่ง (Instantaneous Failure Rate) ที่ลูกค้าซึ่งรอดชีวิตมาจนถึงเวลา t จะยกเลิกบริการในช่วงเวลาถัดไปสั้น ๆ Δt

$$\lambda(t) = \lim_{\Delta t \rightarrow 0} \frac{P(t \leq T < t + \Delta t \mid T \geq t)}{\Delta t} = \frac{f(t)}{S(t)} = -\frac{d}{dt} \ln S(t) \quad (2)$$

3. ฟังก์ชันความเสี่ยงสะสม (Cumulative Hazard Function: $\Lambda(t)$)

คือผลรวมสะสมของความเสี่ยงตั้งแต่จุดเริ่มต้นจนถึงเวลา t

$$\Lambda(t) = \int_0^t \lambda(u) du = -\ln S(t) \iff S(t) = \exp(-\Lambda(t)) \quad (3)$$

2.3 ตัวประมาณค่า Kaplan-Meier (Kaplan-Meier Non-Parametric Estimator)

ในการประมาณค่า $S(t)$ แบบนอนพารามิเตอร์โดยไม่สมมติรูปแบบการแจกแจงล่วงหน้า Kaplan & Meier (1958) ได้พัฒนาสูตรผลคูณสะสม (Product-Limit Formula):

$$\hat{S}(t) = \prod_{t_i \leq t} \left(1 - \frac{d_i}{n_i}\right) \quad (4)$$

เมื่อ $t_1 < t_2 < \dots < t_k$ คือลำดับเวลาที่เกิดเหตุการณ์ยกเลิกบริการจริง, d_i คือจำนวนลูกค้าที่เกิดเหตุการณ์ยกเลิกบริการ ณ เวลา t_i และ n_i คือจำนวนลูกค้าที่ยังคงมีความเสี่ยง (Risk Set) ณ จุดเวลาก่อน t_i

ช่วง ความ เชื่อ มั่น 95% คำนวณ ผ่าน ความ แปรปรวน ของ Greenwood (Greenwood's Formula):

$$\widehat{\text{Var}}(\hat{S}(t)) = \hat{S}(t)^2 \sum_{t_i \leq t} \frac{d_i}{n_i(n_i - d_i)} \quad (5)$$

$$95\% \text{ Confidence Interval: } \hat{S}(t) \pm 1.96 \cdot \sqrt{\widehat{\text{Var}}(\hat{S}(t))} \quad (6)$$

2.4 การทดสอบสมมติฐาน Log-Rank Test (Log-Rank Hypothesis Testing)

เพื่อทดสอบว่าฟังก์ชันการอยู่รอดของกลุ่มลูกค้า K กลุ่มมีความแตกต่างกันอย่างมีนัยสำคัญหรือไม่ กำหนดสมมติฐาน:

$$H_0 : S_1(t) = S_2(t) = \dots = S_K(t) \quad (\text{ทุกกลุ่มมีวิถีการอยู่รอดเหมือนกัน})$$

$$H_1 : \text{มีอย่างน้อยหนึ่งกลุ่มที่มีฟังก์ชันการอยู่รอดแตกต่างออกไป}$$

สถิติทดสอบ Log-Rank (χ^2) เปรียบเทียบผลต่างระหว่างจำนวนเหตุการณ์ที่สังเกตได้จริง (O_j) กับค่าคาดหวังภายใต้ H_0 (E_j):

$$\chi^2 = \sum_{j=1}^K \frac{(O_j - E_j)^2}{V_j} \sim \chi^2(K - 1) \quad (7)$$

3. โครงสร้างชุดข้อมูลและการเตรียมตัวแปร (Dataset Overview & Preprocessing)

ชุดข้อมูล **Telco-Churn.csv** มีโครงสร้างขนาด 7,043 แถว และ 21 คอลัมน์ โดยประกอบด้วยตัวแปรที่นำมาใช้ในการวิเคราะห์ดังนี้:

- **Duration Variable (T):** คอลัมน์ **tenure** แทนระยะเวลา (เดือน) ที่ลูกค้าผูกพันกับผู้ให้บริการ ($0 \leq T \leq 72$)
- **Event Indicator (E):** คอลัมน์ **Churn** แปลงเป็น $E = 1$ เมื่อ Churn = 'Yes' (เกิดเหตุการณ์) และ $E = 0$ เมื่อ Churn = 'No' (ถูก Right-Censored)
- **Segmentation Covariate:** คอลัมน์ **PaymentMethod** แบ่งเป็น 4 กลุ่ม ได้แก่ Electronic check, Mailed check, Bank transfer (automatic) และ Credit card (automatic)


ตารางที่ 1: สถิติเชิงพรรณนาภาพรวมของชุดข้อมูล Telco Churn ($N = 7,043$)

กลุ่มสถานะลูกค้า (Status)	จำนวน (Observations)	สัดส่วน (%)	ค่าเฉลี่ย Tenure (เดือน)
ลูกค้าที่ยกเลิกบริการจริง (Churned Events: $E = 1$)	1,869	26.54%	17.98
ลูกค้าที่ยังคงใช้บริการอยู่ (Censored: $E = 0$)	5,174	73.46%	37.57
รวมประชากรทั้งหมด (Total Cohort)	7,043	100.00%	32.37

4. ผลลัพธ์การวิเคราะห์และกราฟสถิติ (Experimental Results & Diagnostic Plots)

4.1 เส้นโค้งการอยู่รอดของประชากรโดยรวม (Overall Survival Curve)

จากการฟิตโมเดล Kaplan-Meier บนกลุ่มลูกค้าทั้งหมด 7,043 ราย ได้เส้นโค้งการอยู่รอดดังแสดงใน Figure 1




รูปที่ 1: Overall Customer Kaplan-Meier Survival Curve $\hat{S}(t)$: เส้นโค้งการอยู่รอดของลูกค้าภาพรวม ($N = 7,043$) พร้อมช่วงความเชื่อมั่น 95% โดยแสดงค่าความน่าจะเป็น ณ ช่วงเวลาสำคัญ $S(12) = 83.9\%$, $S(24) = 78.4\%$, $S(48) = 68.8\%$ และ $S(72) = 58.7\%$


การแปลผล Figure 1: ค่าความน่าจะเป็นในการอยู่รอดของลูกค้าภาพรวมลดลงอย่างต่อเนื่องแต่คงตัวได้ดี โดยมีลูกค้าถึง 83.9% ที่อยู่รอดเกิน 1 ปี และ 58.7% ที่ยังคงใช้บริการอยู่จนถึงสิ้นสุดการศึกษาที่ 6 ปี (72 เดือน) เนื่องจากมีผู้รอดชีวิตเกิน 50% ตลอด 72 เดือน ค่ามัธยฐานการอยู่รอด (Median Survival Time) จึงมากกว่า 72 เดือน (Not reached within study window)

4.2 เปรียบเทียบเส้นโค้งการอยู่รอดตามช่องทางการชำระเงิน (Survival Curves by Payment Method)

เมื่อจำแนกลูกค้าออกเป็น 4 กลุ่มตามช่องทางการชำระเงิน ได้เส้นโค้งเปรียบเทียบดังแสดงใน Figure 2 และ Figure 3




รูปที่ 2: **Comparative Kaplan-Meier Survival Curves by Payment Method:** เปรียบเทียบเส้นโค้งการอยู่รอดระหว่าง 4 ช่องทางชำระเงิน พบว่ากลุ่ม Electronic check มีอัตราการลดลงของความน่าจะเป็นในการอยู่รอดรวดเร็วและรุนแรงที่สุด โดยตัดผ่านเส้นมัธยฐานที่ $t = 47.0$ เดือน



รูปที่ 3: **Individual Kaplan-Meier Facet Plots with 95% CI:** กราฟแยกย่อย 2×2 พร้อมแถบช่วงความเชื่อมั่น 95% แบบ Greenwood แสดงให้เห็นความแม่นยำสูงเนื่องจากขนาดกลุ่มตัวอย่างที่ใหญ่ ($n \geq 1,522$ ในทุกกลุ่ม)

4.3 การวิเคราะห์ความเสี่ยงสะสม (Cumulative Hazard Function Analysis)


ฟังก์ชันความเสี่ยงสะสม $\Lambda(t) = -\ln S(t)$ แสดงอัตราการสะสมของความเสี่ยงในการยกเลิกบริการตามระยะเวลาการใช้งาน ดังแสดงใน Figure 4



รูปที่ 4: Cumulative Hazard Curves $\Lambda(t)$ by Payment Method: เส้นความเสี่ยงสะสมของกลุ่ม Electronic check มีความชันสูงมาก ($\Lambda(72) > 1.2$) บ่งชี้ว่าลูกค้ารายใหม่ที่เลือกจ่ายด้วยช่องทางนี้มีความเสี่ยงในการยกเลิกบริการสูงตลอดทุกช่วงเวลา ต่างจากระบบอัตโนมัติที่มีความเสี่ยงสะสมคงที่ในระดับต่ำ ($\Lambda(72) \approx 0.28 - 0.30$)

4.4 การแจกแจงอัตรา Churn และระยะเวลา Tenure (Churn Rate & Tenure Distribution)

Figure 5 แสดงอัตรา Churn (%) เปรียบเทียบกับกล่องการแจกแจงระยะเวลา Tenure ของลูกค้าแต่ละกลุ่ม



รูปที่ 5: Churn Rate & Tenure Distribution by Payment Method: ช่าย: อัตรา Churn ของ Electronic check สูงถึง 45.3% ขวา: แผนภาพ Boxplot แสดงค่ามัธยฐาน Tenure ของกลุ่มระบบตัดเงินอัตโนมัติที่สูงถึงประมาณ 43 เดือน

4.5 ตารางสรุปผลลัพธ์เชิงปริมาณ (Quantitative Summary of Results)

ตารางที่ 2: สรุปผลการวิเคราะห์การอยู่รอดเชิงปริมาณ จำแนกตามช่องทางการชำระเงิน

Payment Method	Sample n	Churn d	Censor c	Churn Rate	Median Surv.	Mean Tenure	$S(12)$	$S(24)$	$S(36)$	$S(48)$	$S(72)$
Electronic check	2,365	1,071	1,294	45.3%	47.0 mo.	25.2 mo.	0.727	0.624	0.553	0.493	0.295
Mailed check	1,612	308	1,304	19.1%	> 72 mo.	21.8 mo.	0.828	0.797	0.769	0.740	0.726
Bank transfer (auto)	1,544	258	1,286	16.7%	> 72 mo.	43.7 mo.	0.931	0.902	0.878	0.847	0.745
Credit card (auto)	1,522	232	1,290	15.2%	> 72 mo.	43.3 mo.	0.945	0.913	0.887	0.855	0.758
Overall Population	7,043	1,869	5,174	26.5%	> 72 mo.	32.4 mo.	0.839	0.784	0.738	0.688	0.587

4.6 ผลการทดสอบทางสถิติ Log-Rank Test (Log-Rank Statistical Tests)

ตารางที่ 3: ผลการทดสอบความแตกต่างของเส้นโค้งการอยู่รอด (Multivariate & Pairwise Log-Rank Tests)

การเปรียบเทียบ (Comparison)	Chi-Square (χ^2)	p -value	ข้อสรุปทางสถิติ ($\alpha = 0.001$)
Multivariate (All 4 Groups)	865.2395	3.07×10^{-187}	ปฏิเสธ H_0 (แตกต่างกันอย่างมีนัยสำคัญยิ่ง)
Bank transfer (auto) vs Credit card (auto)	0.8683	0.3514	ไม่แตกต่างกันทางสถิติ (H_0 ถูกยอมรับ)
Electronic check vs Bank transfer (auto)	510.0351	$< 10^{-100}$	แตกต่างกันอย่างมีนัยสำคัญยิ่ง
Electronic check vs Credit card (auto)	539.7402	$< 10^{-100}$	แตกต่างกันอย่างมีนัยสำคัญยิ่ง
Electronic check vs Mailed check	152.4555	$< 10^{-30}$	แตกต่างกันอย่างมีนัยสำคัญยิ่ง
Mailed check vs Bank transfer (auto)	51.0719	$< 10^{-11}$	แตกต่างกันอย่างมีนัยสำคัญยิ่ง
Mailed check vs Credit card (auto)	64.8152	$< 10^{-14}$	แตกต่างกันอย่างมีนัยสำคัญยิ่ง

5. การอภิปรายผลเชิงลึกและข้อมูลเชิงธุรกิจ (In-depth Discussion & Business Insights)

5.1 การวิเคราะห์กลุ่มความเสี่ยงสูง: Electronic Check (High-Risk Segment Analysis)

ลูกค้ากลุ่มที่ชำระผ่าน **Electronic check** เป็นกลุ่มที่มีขนาดใหญ่ที่สุด ($n = 2,365$ หรือ 33.58% ของประชากร) แต่กลับมีอัตราการยกเลิกบริการที่สูงที่สุดถึง 45.3% (1,071 ราย) และมี **Median Survival Time** เท่ากับ 47.0 เดือน

- **พฤติกรรมและความเสียดทานในการชำระ (Payment Friction):** การจ่ายผ่านเช็คอิเล็กทรอนิกส์มักเป็นการจ่ายแบบ Manual ในแต่ละรอบบิล ทำให้ลูกค้าต้องเผชิญกับ “จุดตัดสินใจ (Decision Point)” ทุก ๆ เดือนว่าจะชำระต่อหรือยกเลิกบริการ
- **ความสัมพันธ์กับสัญญาแบบ Month-to-Month:** กลุ่มลูกค้าเช็คอิเล็กทรอนิกส์ส่วนใหญ่มีสัดส่วนสัญญาแบบรายเดือนสูง ทำให้ความยืดหยุ่นในการยกเลิกบริการทำได้ง่ายกว่ากลุ่มที่มีสัญญาระยะยาว

5.2 ประสิทธิภาพของระบบชำระเงินอัตโนมัติ (Automatic Payment Channels)

กลุ่มลูกค้าที่ใช้ **Bank transfer (automatic)** และ **Credit card (automatic)** มีคุณลักษณะการอยู่รอดที่ดีเยี่ยมและใกล้เคียงกันมาก โดยผลการทดสอบ Pairwise Log-Rank ยืนยันว่าไม่มีความแตกต่างกันอย่างมีนัยสำคัญทางสถิติ ($p = 0.3514$):

- อัตรา Churn ต่ำมากเพียง 15.2% – 16.7%
- ค่าความน่าจะเป็นในการอยู่รอดเกิน 2 ปี ($S(24)$) สูงเกิน 90% (90.2% – 91.3%)
- **กลไกเชิงพฤติกรรม:** ระบบตัดเงินอัตโนมัติช่วยขจัดความตระหนักรู้ถึงค่าใช้จ่ายในแต่ละรอบบิล (Pain of Paying) และลดความยุ่งยากในการทำธุรกรรม ส่งผลให้ลูกค้าคงสถานะการใช้บริการอย่างยาวนาน

5.3 พฤติกรรมเฉพาะตัวของกลุ่ม Mailed Check (Mailed Check Loyalty Dynamics)

กลุ่ม **Mailed check** มีอัตรา Churn รวมค่อนข้างต่ำ (19.1%) และมีค่า $S(72) = 72.6\%$ แต่มีค่าเฉลี่ย Tenure สั้น (21.8 เดือน):

- ในช่วง 12 เดือนแรก มีอัตราการลดลงของเส้นการอยู่รอดที่ค่อนข้างชัน ($S(12) = 82.8\%$) ซึ่งสะท้อนถึงกลุ่มผู้ทดลองใช้บริการระยะสั้น
- แต่เมื่อลูกค้ากลุ่มนี้ผ่านช่วง 24 เดือนแรกไปได้ เส้นโค้งการอยู่รอดจะแบนราบลงอย่างเห็นได้ชัด ($S(72) = 72.6\%$) แสดงว่าลูกค้าที่เหลืออยู่คือกลุ่มผู้ใช้ที่มีความภักดีสูง (Brand Loyalists) เช่น กลุ่มผู้สูงอายุหรือลูกค้าดั้งเดิม

6. ข้อเสนอแนะเชิงกลยุทธ์ (Strategic Recommendations)

ข้อเสนอแนะเชิงกลยุทธ์สำหรับฝ่ายบริหารและฝ่ายการตลาด:

1. **แคมเปญ กระตุ้น การ เปลี่ยน ผ่าน สู่ Auto-Pay (Incentivize Auto-Pay Migration):**
มอบส่วนลดพิเศษ เช่น ส่วนลดค่าบริการ \$5 ต่อเดือน เป็นเวลา 6 เดือน สำหรับลูกค้าที่เปลี่ยนช่องทางจาก Electronic check หรือ Mailed check มาเป็นระบบตัดบัตรเครดิตหรือบัญชีธนาคารอัตโนมัติ ซึ่งจะช่วยลด Churn Rate ได้ทันทีกว่า 28–30%
2. **การแทรกแซงเชิงรุกในช่วง Tenure 0–12 เดือน (Early Onboarding Intervention):**
จากกราฟ Hazard อัตราเสี่ยงต่อการยกเลิกจะสะสมตัวเร็วที่สุดในช่วงปีแรก ควรจัดทีม Customer Success ติดตามความพึงพอใจและเสนอสัญญารายปีพร้อมข้อเสนอพิเศษก่อนที่ลูกค้าจะเข้าสู่เดือนที่ 12
3. **ระบบแจ้งเดือนและชำระเงินแบบ One-Click Billing:** ปรับปรุงกระบวนการชำระเงินของ Electronic check ให้มีความสะดวกรวดเร็ว ลดความยุ่งยากของขั้นตอนทางธุรกรรมเพื่อลดแรงจูงใจในการยกเลิกบริการ

7. สรุปผลการดำเนินงาน (Conclusion)

การวิเคราะห์การอยู่รอดด้วยแบบจำลอง Kaplan-Meier บนชุดข้อมูล Telco Churn ช่วยให้เราเข้าใจพลวัตของระยะเวลาในการคงอยู่ของลูกค้าได้อย่างแม่นยำเหนือกว่าแบบจำลองการถดถอยทั่วไป ผลการทดสอบทางสถิติ Log-Rank Test ($\chi^2 = 865.24, p = 3.07 \times 10^{-187}$) ชี้ชัดว่าช่องทางการชำระเงินเป็นปัจจัยที่มีอิทธิพลต่อความอยู่รอดของลูกค้าอย่างมีนัยสำคัญยิ่ง โดยกลุ่มระบบตัดเงินอัตโนมัติมีประสิทธิภาพในการรักษาสถานลูกค้าสูงสุด ($S(24) > 90\%$) ในขณะที่กลุ่ม Electronic check เป็นกลุ่มความเสี่ยงสูงที่ต้องได้รับการปรับปรุงเชิงกลยุทธ์อย่างเร่งด่วน

สรุปผลลัพธ์ (Summary of Results)

หัวข้อ	ผลลัพธ์และข้อสรุป
ชุดข้อมูล	Telco Customer Churn ($N = 7,043$): Churn = 1,869 (26.54%), Censored = 5,174 (73.46%)
Overall Survival	$S(12) = 0.839$, $S(24) = 0.784$, $S(48) = 0.688$, $S(72) = 0.587$ มีอัตราการอยู่รอดภาพรวม > 72 เดือน (อัตราการรอดชีวิตเกิน 50% ตลอดช่วงศึกษา)
กลุ่มความเสี่ยงสูงสุด	Electronic check ($n = 2,365$): Churn Rate = 45.3% , Median Survival = 47.0 เดือน $S(12) = 0.727 \rightarrow S(24) = 0.624 \rightarrow S(72) = 0.295$
กลุ่มความเสี่ยงต่ำสุด	Credit card (auto) (15.2%) & Bank transfer (auto) (16.7%): $S(24) > 90\%$ มีอัตราการอยู่รอด > 72 เดือน และ Mean Tenure > 43 เดือน
Log-Rank Test	Multivariate $\chi^2 = 865.2395$, $p = 3.07 \times 10^{-187}$ (ปฏิเสธ H_0) Pairwise: Auto channels ไม่ต่างกัน ($p = 0.3514$), Electronic check แย่กว่าทุกกลุ่ม ($p < 10^{-30}$)
ข้อเสนอแนะเชิงกลยุทธ์	รณรงค์เปลี่ยนเป็น Auto-Pay (ลด Churn ทันที 28%) และติดตามลูกค้าใหม่ในช่วง 0 – 12 เดือน

Appendix: Full Jupyter Notebook Code & Output

รายละเอียดต่อไปนี้เป็นโค้ด Python ที่ใช้แก้ปัญหาและวิเคราะห์ชุดข้อมูล Telco Churn พร้อมผลลัพธ์และกราฟทั้งหมด ซึ่งได้รันจริงจาก Jupyter Notebook (Assignment_3_Regression.ipynb)

Jupyter Notebook: Assignment_3_Regression.ipynb (Telco Churn Survival Analysis)

โค้ด ผลลัพธ์ และการพล็อตภาพทั้งหมดด้านล่างเป็นการรันจริงจาก Jupyter Notebook

In [1]:

```
1 import os
2 import numpy as np
3 import pandas as pd
4 import matplotlib.pyplot as plt
5 import matplotlib.font_manager as fm
6 from lifelines import KaplanMeierFitter, NelsonAalenFitter
7 from lifelines.statistics import multivariate_logrank_test,
   pairwise_logrank_test
8
9 # --- Robust Sarabun Font Setup ---
10 font_dir = os.path.join(os.environ.get('LOCALAPPDATA', ''), 'Microsoft', '
   Windows', 'Fonts')
11 sarabun_r_path = os.path.join(font_dir, 'Sarabun-Regular.ttf')
12 sarabun_b_path = os.path.join(font_dir, 'Sarabun-Bold.ttf')
13
14 if os.path.exists(sarabun_r_path):
15     fm.fontManager.addfont(sarabun_r_path)
16 if os.path.exists(sarabun_b_path):
17     fm.fontManager.addfont(sarabun_b_path)
18
19 plt.rcParams['font.family'] = 'Sarabun'
20 plt.rcParams['font.size'] = 12
21 plt.rcParams['axes.unicode_minus'] = False
22
23 # --- Data Loading ---
24 df = pd.read_csv('Telco-Churn.csv')
25 T = df['tenure']
26 E = (df['Churn'] == 'Yes').astype(int)
27
28 print(f"Telco Churn Dataset Loaded Successfully. Total Observations N = {len(
   df):,}")
```

```

29 print(f"Observed Churn Events (E=1): {E.sum():,} ({E.mean()*100:.2f}%")
30 print(f"Right-Censored Retained Customers (E=0): {(1-E).sum():,} ({(1-E).mean()
    (*100:.2f}%)")
31
32 df[['customerID', 'tenure', 'PaymentMethod', 'Contract', 'MonthlyCharges', '
    TotalCharges', 'Churn']].head()

```

Out[1]:

Telco Churn Dataset Loaded Successfully. Total Observations N = 7,043

Observed Churn Events (E=1): 1,869 (26.54%)

Right-Censored Retained Customers (E=0): 5,174 (73.46%)

	customerID	tenure	...	TotalCharges	Churn
0	7590-VHVEG	1	...	29.85	No
1	5575-GNVDE	34	...	1889.5	No
2	3668-QPYBK	2	...	108.15	Yes
3	7795-CFOCW	45	...	1840.75	No
4	9237-HQITU	2	...	151.65	Yes

[5 rows x 7 columns]

2. Overall Kaplan-Meier Survival Curve

We fit the Kaplan-Meier survival estimator on the full cohort ($N = 7,043$) to establish the baseline population survival trajectory $\hat{S}(t)$ over tenure.

In [2]:

```

1  # --- Overall Survival Estimation ---
2  kmf_overall = KaplanMeierFitter()
3  kmf_overall.fit(T, event_observed=E, label='All Customers (N = 7,043)')
4
5  fig, ax = plt.subplots(figsize=(8.5, 5))
6  kmf_overall.plot_survival_function(ax=ax, color='#1e3a8a', linewidth=2.5,
    ci_show=True, ci_alpha=0.2)
7
8  # Annotate Key Milestones
9  milestones = [12, 24, 48, 72]
10 for m in milestones:
11     if m in kmf_overall.survival_function_.index:
12         surv_val = kmf_overall.predict(m)
13         ax.plot(m, surv_val, marker='o', markersize=6, color='#dc2626')
14         ax.annotate(f"{surv_val:.1%}\n(t={m})", (m, surv_val), textcoords="
    offset points",

```

```

15         xytext=(0, 10), ha='center', fontsize=9, fontweight='bold'
16     )
17     ax.set_title('Overall Customer Kaplan-Meier Survival Curve  $\hat{S}(t)$ ',
18                 fontsize=14, fontweight='bold', pad=12)
19     ax.set_xlabel('Tenure (Months)', fontsize=12)
20     ax.set_ylabel('Survival Probability  $S(t)$ ', fontsize=12)
21     ax.set_ylim(0, 1.05)
22     ax.set_xlim(0, 75)
23     ax.grid(True, linestyle='--', alpha=0.5)
24     plt.tight_layout()
25     plt.savefig('plot_1_overall_km.pdf', bbox_inches='tight')
26     plt.show()

```




Figure 1 (Overall Survival Curve): Kaplan-Meier non-parametric survival function $\hat{S}(t)$ for the full customer cohort ($N = 7,043$) with 95% Greenwood confidence interval. Milestone annotations illustrate that 83.9% of customers survive past 1 year ($t = 12$), 78.4% survive past 2 years ($t = 24$), and 58.7% remain active at 6 years ($t = 72$). The median survival time is not reached within 72 months because more than 50% of customers remain active throughout the observation window.

3. Comparative Survival Analysis by Payment Method

We segment customers into 4 distinct groups based on PaymentMethod to compare their survival trajectories and hazard characteristics.

In [3]:

```
1 methods = ['Electronic check', 'Mailed check', 'Bank transfer (automatic)', '
    Credit card (automatic)']
2 palette = {
3     'Electronic check': '#dc2626',
4     'Mailed check': '#ea580c',
5     'Bank transfer (automatic)': '#2563eb',
6     'Credit card (automatic)': '#16a34a'
7 }
8
9 fig, ax = plt.subplots(figsize=(9.5, 5.5))
10 kmf_dict = {}
11
12 for method in methods:
13     mask = (df['PaymentMethod'] == method)
14     kmf = KaplanMeierFitter()
15     kmf.fit(T[mask], event_observed=E[mask], label=method)
16     kmf_dict[method] = kmf
17     kmf.plot_survival_function(ax=ax, color=palette[method], linewidth=2.2,
18                               ci_show=True, ci_alpha=0.12)
19
20 ax.set_title('Comparative Kaplan-Meier Survival Curves by Payment Method',
21             fontsize=14, fontweight='bold', pad=12)
22 ax.set_xlabel('Tenure (Months)', fontsize=12)
23 ax.set_ylabel('Survival Probability  $S(t)$ ', fontsize=12)
24 ax.set_ylim(0, 1.05)
25 ax.set_xlim(0, 75)
26 ax.axhline(0.5, color='gray', linestyle=':', alpha=0.7, label='Median Survival
    Threshold ( $S(t)=0.5$ )')
27 ax.grid(True, linestyle='--', alpha=0.5)
28 ax.legend(title='Payment Method', loc='lower left', frameon=True, framealpha
    =0.9)
29 plt.tight_layout()
30 plt.savefig('plot_2_km_by_payment.pdf', bbox_inches='tight')
31 plt.show()
```




Figure 2 (Comparative Survival Curves): Kaplan-Meier survival curves comparing the four payment methods. Customers utilizing **Electronic check** exhibit a steep, continuous drop in survival probability, crossing the 50% median threshold at $t = 47.0$ months. Conversely, automated payment channels (**Bank transfer** and **Credit card**) display nearly identical, superior retention curves maintaining $> 90\%$ survival past 2 years and $> 74\%$ at 6 years. **Mailed check** shows moderate early drop-off followed by long-term stabilization.

4. Individual Facet Plots with Confidence Bands

Plotting each payment method separately in a 2×2 grid to clearly inspect the 95% Greenwood confidence intervals and group characteristics.

In [4]:

```
1 fig, axes = plt.subplots(2, 2, figsize=(11, 8), sharex=True, sharey=True)
2 axes = axes.flatten()
3
4 for i, method in enumerate(methods):
5     ax = axes[i]
6     mask = (df['PaymentMethod'] == method)
7     kmf = kmf_dict[method]
8     kmf.plot_survival_function(ax=ax, color=palette[method], linewidth=2.2,
9                               ci_show=True, ci_alpha=0.25)
10
11     n_total = len(T[mask])
12     n_churn = E[mask].sum()
```



```

12     churn_rate = (n_churn / n_total) * 100
13     med_val = kmf.median_survival_time_
14     med_str = f"{med_val:.1f} mo." if not np.isinf(med_val) else "> 72 mo. (N/
    A)"
15
16     ax.set_title(f"{method}\n(n={n_total:}, Churn={churn_rate:.1f}%, Median={
    med_str})", fontsize=11, fontweight='bold')
17     ax.set_ylim(0, 1.05)
18     ax.set_xlim(0, 75)
19     ax.grid(True, linestyle='--', alpha=0.5)
20     ax.set_xlabel('Tenure (Months)', fontsize=10)
21     ax.set_ylabel('Survival Probability  $S(t)$ ', fontsize=10)
22     ax.axhline(0.5, color='gray', linestyle=':', alpha=0.5)
23
24     fig.suptitle('Individual Kaplan-Meier Survival Estimates with 95% Confidence
    Intervals', fontsize=14, fontweight='bold', y=0.98)
25     plt.tight_layout()
26     plt.savefig('plot_3_km_grid_by_payment.pdf', bbox_inches='tight')
27     plt.close()
28     print("Plot 3 saved to plot_3_km_grid_by_payment.pdf")

```

Out[4]:

```
Plot 3 saved to plot_3_km_grid_by_payment.pdf
```




Figure 3 (Individual Survival Facets with 95% CI): 2×2 facet grid of Kaplan-Meier survival curves with 95% confidence bands for each payment method. The tight confidence intervals across all four subplots confirm high statistical precision resulting from large subgroup sample sizes ($n \geq 1,522$ per group).

5. Cumulative Hazard Function Analysis

The cumulative hazard function $\Lambda(t) = \int_0^t \lambda(u) du = -\ln S(t)$ models the accumulated risk of customer churn over time.

In [5]:

```
1 fig, ax = plt.subplots(figsize=(9, 5.5))
2 naf_dict = {}
3
4 for method in methods:
5     mask = (df['PaymentMethod'] == method)
6     naf = NelsonAalenFitter()
7     naf.fit(T[mask], event_observed=E[mask], label=method)
8     naf_dict[method] = naf
9     naf.plot_cumulative_hazard(ax=ax, color=palette[method], linewidth=2.2,
10                               ci_show=True, ci_alpha=0.12)
```

```

11 ax.set_title('Cumulative Hazard  $\Lambda(t)$  by Payment Method', fontsize=14,
    fontweight='bold', pad=12)
12 ax.set_xlabel('Tenure (Months)', fontsize=12)
13 ax.set_ylabel('Cumulative Hazard  $\Lambda(t) = -\ln S(t)$ ', fontsize=12)
14 ax.set_xlim(0, 75)
15 ax.grid(True, linestyle='--', alpha=0.5)
16 ax.legend(title='Payment Method', loc='upper left', frameon=True, framealpha
    =0.9)
17 plt.tight_layout()
18 plt.savefig('plot_4_cumulative_hazard.pdf', bbox_inches='tight')
19 plt.show()

```




Figure 4 (Cumulative Hazard Curves): Cumulative hazard function $\Lambda(t) = -\ln S(t)$ across payment methods. Electronic check exhibits a steeply ascending, quasi-linear hazard rate surpassing $\Lambda(72) > 1.2$, indicating severe ongoing churn risk. In contrast, automated methods exhibit flat, gradual hazard accumulation ($\Lambda(72) \approx 0.28$ to 0.30).

6. Distribution Analysis of Churn Rate & Tenure

Examining the overall churn percentage and the distribution of customer tenure across the four payment methods.

In [6]:

```
1 fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(12, 5))
2
3 # Churn Rate Bar Chart
4 churn_summary = df.groupby('PaymentMethod')['Churn'].apply(lambda x: (x == '
    Yes').mean() * 100).reindex(methods)
5 bars = ax1.bar(range(len(methods)), churn_summary, color=[palette[m] for m in
    methods], edgecolor='black', alpha=0.85, width=0.6)
6 ax1.set_xticks(range(len(methods)))
7 ax1.set_xticklabels([m.replace(' (automatic)', '\n(auto)') for m in methods],
    fontsize=10)
8 ax1.set_ylabel('Churn Rate (%)', fontsize=11)
9 ax1.set_title('Customer Churn Rate by Payment Method', fontsize=12, fontweight
    ='bold')
10 ax1.set_ylim(0, 55)
11 ax1.grid(True, linestyle='--', axis='y', alpha=0.5)
12 for bar in bars:
13     yval = bar.get_height()
14     ax1.text(bar.get_x() + bar.get_width()/2.0, yval + 1, f"{yval:.1f}%", ha='
    center', va='bottom', fontweight='bold', fontsize=10)
15
16 # Tenure Boxplot
17 data_to_plot = [df[df['PaymentMethod'] == m]['tenure'] for m in methods]
18 bp = ax2.boxplot(data_to_plot, patch_artist=True, tick_labels=[m.replace(' (
    automatic)', '\n(auto)') for m in methods],
19                 medianprops=dict(color='black', linewidth=1.5))
20 for patch, m in zip(bp['boxes'], methods):
21     patch.set_facecolor(palette[m])
22     patch.set_alpha(0.6)
23 ax2.set_ylabel('Tenure (Months)', fontsize=11)
24 ax2.set_title('Tenure Distribution by Payment Method', fontsize=12, fontweight
    ='bold')
25 ax2.grid(True, linestyle='--', axis='y', alpha=0.5)
26
27 plt.tight_layout()
28 plt.savefig('plot_5_churn_distribution.pdf', bbox_inches='tight')
29 plt.show()
```




Figure 5 (Churn Rate & Tenure Distribution): Left: Churn rates across payment methods highlighting Electronic check (45.3%) vs. Mailed check (19.1%), Bank transfer (16.7%), and Credit card (15.2%). Right: Boxplots of tenure demonstrating substantially higher customer loyalty and tenure in automated payment channels (median tenure ≈ 43 months) compared to manual payment methods.

7. Statistical Hypothesis Testing & Quantitative Summary

We perform the **Multivariate Log-Rank Test** to test $H_0 : S_1(t) = S_2(t) = S_3(t) = S_4(t)$, followed by pairwise comparisons and milestone survival metrics compilation.

In [7]:

```
1 # --- Log-Rank Hypothesis Testing ---
2 logrank_res = multivariate_logrank_test(T, df['PaymentMethod'], E)
3 print("="*60)
4 print("MULTIVARIATE LOG-RANK TEST RESULTS")
5 print("="*60)
6 print(f"Chi-Square: {logrank_res.test_statistic:.4f}")
7 print(f"p-value:      {logrank_res.p_value:.4e}")
8 print(f"df:          {logrank_res.degrees_of_freedom}")
9 print(f"Conclusion: Reject H0 at alpha = 0.001")
10
11 pairwise_res = pairwise_logrank_test(T, df['PaymentMethod'], E)
12 print("\n" + "="*60)
13 print("PAIRWISE LOG-RANK TEST SUMMARY")
14 print("="*60)
15 for pair, row in pairwise_res.summary.iterrows():
16     p_val = row['p']
17     p_str = f"{p_val:.4e}" if p_val < 0.001 else f"{p_val:.4f}"
18     print(f"{pair[0][:15]:<16} vs {pair[1][:15]:<16} | chi2={row['test_statistic']:>7.2f} | p={p_str}")
19
20 # --- Quantitative Summary Table ---
21 summary_list = []
22 for m in methods:
23     mask = (df['PaymentMethod'] == m)
24     kmf = kmf_dict[m]
25     n_tot = len(T[mask])
26     n_ev = E[mask].sum()
27     n_cens = n_tot - n_ev
28     ch_rate = (n_ev / n_tot) * 100
29     med_s = kmf.median_survival_time_
30     med_str = f"{med_s:.1f} mo." if not np.isinf(med_s) else "> 72 mo."
31     mean_t = T[mask].mean()
32
33     summary_list.append({
34         'Payment Method': m,
35         'Sample (n)': n_tot,
36         'Churned (d)': n_ev,
```

```

37         'Censored (c)': n_cens,
38         'Churn Rate': f"{ch_rate:.1f}%",
39         'Median Survival': med_str,
40         'Mean Tenure': f"{mean_t:.1f} mo.",
41         'S(12 mo.)': f"{kmf.predict(12):.3f}",
42         'S(24 mo.)': f"{kmf.predict(24):.3f}",
43         'S(36 mo.)': f"{kmf.predict(36):.3f}",
44         'S(48 mo.)': f"{kmf.predict(48):.3f}",
45         'S(60 mo.)': f"{kmf.predict(60):.3f}",
46         'S(72 mo.)': f"{kmf.predict(72):.3f}"
47     })
48
49 sum_df = pd.DataFrame(summary_list)
50 print("\n" + "="*60)
51 print("COMPREHENSIVE SURVIVAL SUMMARY TABLE")
52 print("="*60)
53 sum_df

```

Out[7]:

```

=====
MULTIVARIATE LOG-RANK TEST RESULTS
=====
Chi-Square: 865.2395
p-value:    3.0665e-187
df:         3
Conclusion: Reject H0 at alpha = 0.001

=====
PAIRWISE LOG-RANK TEST SUMMARY
=====
Bank transfer ( vs Credit card (au | chi2=  0.87 | p=0.3514
Bank transfer ( vs Electronic chec | chi2= 510.04 | p=6.2314e-113
Bank transfer ( vs Mailed check    | chi2=  51.07 | p=8.9046e-13
Credit card (au vs Electronic chec | chi2= 539.74 | p=2.1476e-119
Credit card (au vs Mailed check    | chi2=  64.82 | p=8.2263e-16
Electronic chec vs Mailed check    | chi2= 152.46 | p=5.0383e-35

=====
COMPREHENSIVE SURVIVAL SUMMARY TABLE
=====

```

	Payment Method	Sample (n)	...	S(60 mo.)	S(72 mo.)
0	Electronic check	2365	...	0.413	0.295
1	Mailed check	1612	...	0.732	0.726

2	Bank transfer (automatic)	1544	...	0.804	0.745
3	Credit card (automatic)	1522	...	0.831	0.758

[4 rows x 13 columns]

8. Summary of Results & Domain Discussion

Summary of Quantitative Findings:

1. Electronic Check Customers (High Risk Channel):

- Has the largest subgroup ($n = 2,365$, 33.6% of total cohort) but suffers an alarmingly high churn rate of 45.3% (1,071 churn events).
- Reaches median survival time at 47.0 **months** ($S(47.0) = 0.500$).
- Only 72.7% survive past 1 year ($t = 12$), dropping to 62.4% at 2 years ($t = 24$) and 29.5% at 6 years ($t = 72$).
- **Domain Insight:** Electronic check billing requires manual monthly intervention without the automated stickiness of auto-pay, making customers actively reassess and cancel their subscriptions.

2. Automatic Payment Channels (Bank Transfer & Credit Card - Low Risk Loyalty Channels):

- Both automated channels display exceptional, virtually identical survival characteristics ($p = 0.351$, not statistically different from each other).
- **Credit Card (automatic):** Churn rate = 15.2%, $S(12) = 0.945$, $S(24) = 0.913$, $S(72) = 0.758$, Mean tenure = 43.3 months.
- **Bank Transfer (automatic):** Churn rate = 16.7%, $S(12) = 0.931$, $S(24) = 0.902$, $S(72) = 0.745$, Mean tenure = 43.7 months.
- Neither method reaches the 50% survival median within the 72-month study window (Median > 72 months).
- **Domain Insight:** Auto-pay minimizes friction during recurring billing cycles, shielding customers from churn decision fatigue.

3. Mailed Check Customers (Moderate Churn with Long-Term Stabilization):

- Sample size $n = 1,612$, Churn rate = 19.1%, Mean tenure = 21.8 months.
- Exhibits steep initial churn ($S(12) = 0.828$, $S(24) = 0.797$) during trial onboarding, but the curve flattens significantly after 2 years ($S(72) = 0.726$).

Strategic Business Recommendations:

- **Incentivize Auto-Pay Adoption:** Implement promotional discounts (\$5/mo discount for 6 months) to convert Electronic check and Mailed check users to Credit card or Bank transfer auto-pay.
- **Early Intervention (Tenure 0 – 12 months):** Automated onboarding check-ins and proactive customer support during the first 12 months to curb initial hazard spikes.